

拉格朗日对偶性

预备知识

对于下文涉及到的 $\min_{\mathbf{x}}$ 、 $\max_{\boldsymbol{\alpha}, \boldsymbol{\beta}: \alpha_i \geq 0}$ 、凸函数、仿射函数等基本概念可参考此博客[拉格朗日对偶，从0到完全理解_frostime的博客](#)的 2. 预备的数学知识

正文

原始问题

假设 $f(\mathbf{x})$, $c_i(\mathbf{x})$, $h_j(\mathbf{x})$ 是定义在 \mathbf{R}^n 上的连续可微函数。考虑约束最优化问题：

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & c_i(\mathbf{x}) \leq 0, \quad i = 1, 2, \dots, k \\ & h_j(\mathbf{x}) = 0, \quad j = 1, 2, \dots, l \end{aligned} \quad (\text{B.1})$$

称此约束最优化问题为原始最优化问题或原始问题。

构造广义拉格朗日函数：

$$L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = f(\mathbf{x}) + \sum_{i=1}^k \alpha_i c_i(\mathbf{x}) + \sum_{j=1}^l \beta_j h_j(\mathbf{x}) \quad (\text{B.2})$$

先说**结论**：

原最优化问题式A.7与 $\min_{\mathbf{x}} \max_{\boldsymbol{\alpha}, \boldsymbol{\beta}: \alpha_i \geq 0} L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$ 等价的，即他们有相同的解。

下面开始说明，这两个为什么等价：

将 $\max_{\boldsymbol{\alpha}, \boldsymbol{\beta}: \alpha_i \geq 0} L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta})$ 这部分，记为 $\theta_P(\mathbf{x})$ 。假设给定某个 \mathbf{x} ，如果 \mathbf{x} 不满足原始问题的约束条件，即存在某个 i 使得 $c_i(\mathbf{x}) > 0$ 或者存在某个 j 使得 $h_j(\mathbf{x}) \neq 0$ ，那么就有

$$\theta_P(\mathbf{x}) = \max_{\boldsymbol{\alpha}, \boldsymbol{\beta}: \alpha_i \geq 0} [f(\mathbf{x}) + \sum_{i=1}^k \alpha_i c_i(\mathbf{x}) + \sum_{j=1}^l \beta_j h_j(\mathbf{x})] = +\infty \quad (\text{B.3})$$

相反的，如果 \mathbf{x} 满足原始问题的约束条件，那么 $\theta_P(\mathbf{x}) = f(\mathbf{x})$ 。因此，

$$\theta_P(\mathbf{x}) = \begin{cases} f(\mathbf{x}), & \mathbf{x} \text{ 满足原始问题约束} \\ +\infty, & \text{其它} \end{cases} \quad (\text{B.4})$$

所以极小化 $\theta_P(\mathbf{x})$ ，即 $\min_{\mathbf{x}} \theta_P(\mathbf{x})$ 与原始问题等价，将 $\min_{\mathbf{x}} \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{x}, \alpha, \beta)$ 成为拉格朗日函数的极小极大问题。这样一来，就把原始最优化问题表示为广义拉格朗日函数的极小极大值问题。为了方便，定义原始问题的最优值：

$$p^* = \min_{\mathbf{x}} \theta_P(\mathbf{x}) \quad (\text{B.5})$$

称为原始问题的值。

对偶问题

再定义广义拉格朗日函数的极大极小问题：

$$\max_{\alpha, \beta: \alpha_i \geq 0} \min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta) \quad (\text{B.6})$$

将 $\min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta)$ 这部分，记为 $\theta_D(\alpha, \beta)$ 。再来个转换，将广义拉格朗日函数的极大极小问题表示为约束最优化问题：

$$\begin{aligned} \max_{\alpha, \beta} \theta_D(\alpha, \beta) &= \max_{\alpha, \beta} \min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta) \\ \text{s.t. } \alpha_i &\geq 0, \quad i = 1, 2, \dots, k \end{aligned} \quad (\text{B.7})$$

式B.7称为原始问题的对偶问题。为了方便，定义对偶问题的最优值：

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) \quad (\text{B.8})$$

称为对偶问题的值。

原始问题和对偶问题的关系

定理1：对偶问题给出了原始问题最优解的下界。由： $\min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta) \leq L(\mathbf{x}, \alpha, \beta) \leq \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{x}, \alpha, \beta)$ ，可知 $\theta_D(\alpha, \beta) \leq \theta_P(\mathbf{x})$ 。当原始问题和对偶问题均最优解时，那么 $\max_{\alpha, \beta: \alpha_i \geq 0} \theta_D(\alpha, \beta) \leq \min_{\mathbf{x}} \theta_P(\mathbf{x})$ ，即

$$d^* = \max_{\alpha, \beta: \alpha_i \geq 0} \min_{\mathbf{x}} L(\mathbf{x}, \alpha, \beta) \leq \min_{\mathbf{x}} \max_{\alpha, \beta: \alpha_i \geq 0} L(\mathbf{x}, \alpha, \beta) = p^*$$

定理2：当 $f(\mathbf{x})$ 和 $c_i(\mathbf{x})$ 为凸函数， $h_j(\mathbf{x})$ 是仿射函数，并且不等式约束是严格可行的，即存在 \mathbf{x} ，对所有 i 有 $c_i(\mathbf{x}) < 0$ ，则存在 $\mathbf{x}^*, \alpha^*, \beta^*$ ，分别是原始问题，对偶问题的解，且：

$$p^* = d^* = L(\mathbf{x}^*, \alpha^*, \beta^*)$$

定理3：当 $f(\mathbf{x})$ 和 $c_i(\mathbf{x})$ 为凸函数， $h_j(\mathbf{x})$ 是仿射函数，并且不等式约束是严格可行的，即存在 \mathbf{x} ，对所有 i 有 $c_i(\mathbf{x}) < 0$ ，则 $\mathbf{x}^*, \alpha^*, \beta^*$ 分别是原始问题，对偶问题的解的充分必要条件是 $\mathbf{x}^*, \alpha^*, \beta^*$ 满足KKT条件：

$$\begin{cases} \nabla_{\mathbf{x}} L(\mathbf{x}, \boldsymbol{\alpha}, \boldsymbol{\beta}) = 0 \\ \alpha_i c_i(\mathbf{x}) = 0, i = 1, 2, \dots, k \\ \alpha_i \geq 0, i = 1, 2, \dots, k \\ c_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, k \\ h_j(\mathbf{x}) = 0, j = 1, 2, \dots, l \end{cases} \quad (\text{A.9})$$

引申：

SVM的最优化问题为

$$\begin{aligned} & \min_{w, b} \frac{1}{2} \|w\|^2 \\ & s.t. \quad y_i(w^T x_i + b) \geq 1 \quad (i \in [m]) \end{aligned}$$

可以看出，svm的目标函数、不等式约束条件是凸函数，并且当 \mathbf{x} 不是支持向量时，不等式约束是严格执行的，所以强对偶性成立。在强对偶性成立时，将拉格朗日函数分别对原变量和对偶变量求导，再并令导数等于零，即可得到原变量与对偶变量的数值关系。于是，对偶问题解决了，主问题也就解决了。

那么对偶问题如何解决呢？由于svm的目标函数、不等式约束条件是凸函数，所以KKT条件是对偶问题最优解的充分必要条件，找到满足KKT条件的解就能解决对偶问题。

至此，就说明了为什么满足KKT条件的 $\mathbf{w}^*, \mathbf{b}^*, \boldsymbol{\alpha}^*$ ，这里的 $\mathbf{w}^*, \mathbf{b}^*$ 就是SVM原始问题的最优解。所以，就可以按照这样一个思想来求最优解：如果所有变量的解满足此最优化问题的KKT条件，那么这个最优化问题的解就得到了。